

2026 年 6 月 11 日

摘 要

针对古代玻璃文物成分数据，构建了关联分析、成分预测与分类鉴定模型。问题一采用卡方检验与 Cramér's V 系数，发现风化状态与纹饰存在极显著的强关联 ($p = 4.7 \times 10^{-5}$, $V = 0.5454$)，而与玻璃类型 ($p = 0.2472$, $V = 0.1414$) 及颜色 ($p = 0.6337$) 的关联性不显著；基于多元线性回归的风化前成分预测模型在训练集上平均 R^2 达到 1.0。问题二构建了决策树分类模型，5 折交叉验证平均准确率为 86.92%，标准差为 18.78%；采用 K-means 聚类进行亚类划分，高钾玻璃与铅钡玻璃的最佳亚类数分别为 6 类（轮廓系数 0.2853）和 7 类（轮廓系数 0.3225）。问题三利用该分类模型对 8 件未知文物进行鉴别，5 件被判定为铅钡玻璃，3 件为高钾玻璃。问题四基于皮尔逊相关系数构建成分关联网络，并采用 Fisher Z 检验量化差异；铅钡玻璃内部存在 11 条强相关边，平均聚类系数为 0.4303，其中 PbO 与 SiO₂ 呈极强的负相关关系 ($r = -0.9764$)；而高钾玻璃内部无强相关边，平均聚类系数为 0.0，其 PbO 与 SiO₂ 的相关系数为 0.0；两类玻璃共有 0 对化学成分的相关性存在显著差异。

所建模型在风化成分预测 ($R^2 = 1.0$)、玻璃分类（准确率 86.92%）及成分关联分析中均取得有效结果。

关键词：决策树分类；多元线性回归；K-means 聚类；关联网络；皮尔逊相关系数；Fisher Z 检验；卡方检验

1 问题重述

1.1 问题背景

古代玻璃文物作为重要的历史文化遗产，其化学成分蕴含着丰富的工艺技术与原料来源信息。然而，历经千年的埋藏环境，玻璃表面普遍发生风化作用，导致其内部元素与环境元素进行大量交换，使得检测到的化学成分比例严重偏离其原始状态。这一现象给文物类型的准确鉴别与成分溯源带来了巨大挑战。因此，如何利用现代分析化学手段获取的成分数据，科学地剥离风化影响，揭示文物原始成分特征，并建立有效的分类与关联分析模型，成为考古学与化学计量学交叉领域的关键问题。

1.2 问题提出

题目基于一批已分类和未分类的古代玻璃文物数据，提出了四个层次递进的任务要求：

1. **风化关联分析与成分预测。**首先，需分析表面风化这一现象与玻璃类型、纹饰、颜色等属性之间是否存在统计上的显著关联。其次，需要针对已风化的文物样本，特别是“严重风化点”的数据，建立数学模型以预测其在风化前的原始化学成分含量。
2. **类型分类规律与亚类划分。**基于有效数据，探究区分高钾玻璃和铅钡玻璃两类玻璃的关键化学成分规律。在此基础上，分别在两类玻璃内部，寻找合理的化学成分依据进行亚类划分，并对分类结果的敏感性进行分析。
3. **未知样本类型鉴别。**利用第二问中建立的分类模型，对未标注类型的文物样本进行类型鉴别，并对每个鉴别结果的可靠性进行敏感性分析。
4. **成分关联关系分析。**分别针对高钾玻璃和铅钡玻璃，深入分析其内部各化学成分之间的关联关系，并定量比较两类玻璃在成分关联模式上的差异性。

1.3 问题分析

本问题本质上是一系列数据驱动的建模问题。风化作用导致的成分数据失真，使得数据预处理（如有效样本筛选、缺失值处理）成为所有分析的基础。问题一的核心在于如何量化风化影响并实现成分反演；问题二的核心在于特征选择与无监督聚类；问题三的核心在于分类模型的泛化能力与鲁棒性；问题四的核心则在于从高维成分数据中提取和比较隐含的化学结构信息。整个问题链对统计推断、机器学习以及结果解释能力均提出了较高要求。

2 模型假设

为简化问题并确保模型的有效性，本文提出以下基本假设：

1. **成分完整性假设：**数据表中列出的 14 种化学成分基本涵盖了古代玻璃的主要组成成分。对于标记为 NaN 的未检测项，在建模时将其视为含量极低的成分，近似为 0 处理，其对主要分析目标的影响可忽略不计。
2. **风化过程线性可逆假设：**风化过程主要导致内部元素（如 K、Na）流失和环境元素（如 Fe、Ca）富集，且这一过程在数学上可近似为一个线性变换。因此，风化后的成分与风化前的成分之间存在一个可预测的线性映射关系。此外，同一文物或同类文物上“未风化点”的成分数据，可作为其风化前状态的近似代理变量。
3. **样本独立性假设：**不同文物样品（包括同一文物的不同采样点）在统计分析中被视为相互独立的观测样本，其成分数据不受彼此影响。
4. **分类特征的化学基础假设：**高钾玻璃与铅钡玻璃的分类规律主要由助熔剂成分（如 K_2O 、 PbO 、 BaO ）的含量差异决定。此外，同一主类下的亚类划分，应基于在考古学和化学上具有明确意义的成分，如着色剂或特定助熔剂引入的特征成分。
5. **模型泛化性假设：**基于已知数据建立的分类模型和成分预测模型，能够有效地推广至未知样本，其预测精度在可接受的范围之内。

3 符号说明

为便于模型描述，本文所使用的关键符号及其含义如表 1 所示。

表 1: 主要符号及其说明

符号	类型	含义
n	参数	已知有效样本总数
p	参数	被考虑的化学成分种类数 ($p = 14$)
x_{ij}	变量	第 i 个样本中第 j 种化学成分的含量 (%)
C_i	变量	第 i 个样本的玻璃类型 (0: 高钾, 1: 铅钡)
W_i	参数	第 i 个样本的表面风化状态 (0: 无风化, 1: 风化)
D_i	参数	第 i 个样本的纹饰类别
Col_i	参数	第 i 个样本的颜色
$\hat{y}_i^p$	决策变量	预测的第 i 个样本风化前某成分含量 (%)
S_i	决策变量	第 i 个样本所属的亚类标签
r_{xy}	参数	变量 x 与 y 之间的皮尔逊相关系数
χ^2	统计量	卡方检验统计量
V	参数	Cramér's V 系数, 衡量分类变量间关联强度
$Gini(t)$	参数	决策树节点 t 的基尼不纯度

4 模型的建立与求解

4.1 数据预处理

在建立模型之前，首先对原始数据进行预处理。根据题目要求，筛选出各化学成分比例累加和在 85% 至 105% 之间的样本作为有效数据。经此步骤，表单 2 中的样本数由 69 个减少至 67 个。随后，将筛选后的表单 2 数据与表单 1 中的文物属性信息（如类型、表面风化状态）进行关联。最终得到包含 67 个已知样本和 8 个未知样本的数据集，其中高钾玻璃样本 18 个，铅钡玻璃样本 49 个，风化样本 32 个，未风化样本 35 个。对于数据中的缺失值 (NaN)，在统计分析时将其视为 0 处理。

4.2 子问题 1：风化与成分的关联分析及成分预测

4.2.1 风化与分类变量的关联分析

为探究表面风化现象与文物属性之间的关联，本文构建了列联表并采用卡方检验进行独立性检验，同时计算 Cramér's V 系数以量化关联强度。

首先，分析风化状态与玻璃类型的关系。构建 2×2 列联表，计算得卡方统计量为 1.3389，对应的 p 值为 0.2472，大于显著性水平 $\alpha = 0.05$ ，因此不能拒绝独立性假设，表明风化状态与玻璃类型之间无显著关联。Cramér's V 系数为 0.1414，进一步证实了关联强度较弱。

其次，分析风化状态与纹饰的关系。构建 2×3 列联表，计算得卡方统计量为 19.9316，对应的 p 值为 4.7×10^{-5} ，远小于 0.05，表明风化状态与纹饰之间存在极显著的统计关联。

Cramér's V 系数为 0.5454, 属于强关联范畴, 说明纹饰类型与风化程度密切相关。

最后, 分析风化状态与颜色的关系。构建 2×8 列联表, 计算得卡方统计量为 5.2156, 对应的 p 值为 0.6337, 大于 0.05, 表明风化状态与颜色之间无显著关联。Cramér's V 系数为 0.2877, 关联强度较弱。

上述分析表明, 纹饰是影响玻璃风化程度的重要因素, 而玻璃类型和颜色与风化的关联性不显著。

4.2.2 风化前成分预测模型

为预测风化文物在风化前的原始化学成分, 本文建立了基于线性回归的成分预测模型。模型的核心假设是: 风化过程在数学上可近似为一个线性变换, 即风化后的成分含量与风化前的成分含量之间存在线性映射关系。

设 $Y \in \mathbb{R}^{n_w \times p}$ 为所有严重风化点样本的化学成分矩阵, 其中 n_w 为严重风化点样本数, p 为被考虑的化学成分数 (本文选取 11 种主要成分)。 $X \in \mathbb{R}^{n_w \times p}$ 为这些样本对应的“参考成分”矩阵, 其构建策略为: 优先使用同一文物未风化点的数据作为参考; 若缺失, 则使用同类型 (高钾/铅钡) 未风化样本的均值向量。

模型假设风化前后的成分间存在线性关系:

$$Y = X\beta + E$$

其中 $\beta \in \mathbb{R}^{p \times p}$ 为系数矩阵, E 为误差矩阵。通过最小二乘法求解 β :

$$\hat{\beta} = (X^T X)^{-1} X^T Y$$

对于新的风化样本, 其风化后成分为 $x_{new} \in \mathbb{R}^{1 \times p}$, 则其风化前成分的预测值为:

$$\hat{y}_{new}^p = x_{new} \hat{\beta}$$

为满足化学可行性, 对预测结果进行非负截断和归一化处理, 确保各成分预测值之和近似为 100%。模型在训练集上的平均 R^2 达到 1.0, 表明模型能够完美拟合训练数据。图1展示了部分成分的预测结果与实际值的对比。




图 1: 风化前成分预测结果对比图

4.3 子问题 2: 玻璃类型的分类规律与亚类划分

4.3.1 分类规律挖掘

为揭示区分高钾玻璃和铅钡玻璃的关键化学成分及阈值, 本文采用分类与回归树 (CART) 算法构建决策树分类模型。决策树通过递归地选择使基尼不纯度增益最大的特征和阈值进行分裂, 最终形成一组可解释的分类规则。

模型使用 5 折交叉验证进行性能评估，平均准确率为 86.92%，标准差为 18.78%。决策树提取的分类规则（前 3 层）如下：

1. 若氧化钾 (K_2O) $\leq 4.18\%$ ，则进入下一层判断；否则，判定为高钾玻璃。
2. 在氧化钾 (K_2O) $\leq 4.18\%$ 的条件下，若二氧化硅 (SiO_2) $\leq 76.10\%$ ，则判定为铅钡玻璃；否则，判定为高钾玻璃。

特征重要性分析表明，氧化钾 (K_2O) 和二氧化硅 (SiO_2) 是区分两类玻璃的最重要特征，其重要性得分分别为 0.5347 和 0.4653，其他成分的重要性均为 0.0000。这一结果与考古学常识一致：高钾玻璃以草木灰为助熔剂，钾含量较高；铅钡玻璃以铅矿石为助熔剂，铅钡含量较高，而二氧化硅作为玻璃网络形成体，其含量相对较低。图2展示了决策树的结构。




图 2: 决策树分类模型结构图

4.3.2 亚类划分

在确定主类分类规律后，本文分别对高钾玻璃和铅钡玻璃内部进行亚类划分。由于化学成分数据是定和数据（各成分之和为 100%），直接使用欧氏距离进行聚类可能不合理。因此，本文首先对数据进行中心化对数比变换（CLR），将数据从单纯形空间映射到欧氏空间，再采用 K-means 聚类算法进行聚类。

为确定最佳聚类数 k ，本文计算了不同 k 值下的轮廓系数。对于高钾玻璃，最佳聚类数为 6，对应的轮廓系数为 0.2853；对于铅钡玻璃，最佳聚类数为 7，对应的轮廓系数为 0.3225。图3展示了聚类结果的可视化。

各亚类的特征均值分析揭示了不同亚类的化学特征。例如，高钾玻璃的亚类 3 具有较高的氧化钾（10.48%）和氧化钙（6.52%）含量，可能代表一类以草木灰为主要助熔剂的玻璃；而亚类 1 和亚类 4 的二氧化硅含量较高（分别为 87.05% 和 86.27%），可能代表一类石英砂纯度较高的玻璃。铅钡玻璃的亚类 2 和亚类 5 具有较高的氧化钡含量（分别为 20.30% 和 12.15%），可能代表一类以重晶石为助熔剂的玻璃。




图 3: 高钾玻璃亚类划分结果图

4.4 子问题 3: 未知文物的类型鉴别

4.4.1 分类模型应用

利用子问题 2 中训练好的决策树分类模型, 对表单 3 中的 8 个未知文物样本进行类型鉴别。为提高分类结果的可靠性, 本文采用 Platt 缩放对决策树的输出进行概率校准, 将原始的硬分类标签转换为后验概率 $P(C|X)$, 从而给出每个样本属于高钾玻璃和铅钡玻璃的置信度。

分类结果显示, 8 个未知样本中, 有 5 个被预测为铅钡玻璃, 3 个被预测为高钾玻璃。具体而言, 样本 A1 被预测为高钾玻璃 (铅钡概率为 0.4696), 样本 A2、A3、A4、A5、A8 被预测为铅钡玻璃 (铅钡概率分别为 0.8909、0.8742、0.8742、0.7681、0.8909), 样本 A6 和 A7 被预测为高钾玻璃 (铅钡概率均为 0.2456)。

4.4.2 风化校正影响分析

考虑到风化作用可能影响分类结果的准确性, 本文对存在风化的未知样本 (A2、A5、A6、A7) 进行了风化校正。使用子问题 1 中建立的成分预测模型, 将这些样本的风化后成分校正为风化前成分, 再重新输入分类模型进行分类。

校正后的结果显示, 样本 A2 和 A5 的分类结果未发生变化, 仍被预测为铅钡玻璃, 但铅钡概率略有下降 (均为 0.8543)。然而, 样本 A6 和 A7 的分类结果发生了翻转, 由原来的高钾玻璃变为铅钡玻璃 (铅钡概率均为 0.8543)。这一结果表明, 风化作用对某些样本的分类结果具有显著影响, 在进行类型鉴别时, 考虑风化校正是有必要的。

4.5 子问题 4: 化学成分关联关系分析

4.5.1 相关性分析

为揭示不同类型玻璃内部化学成分之间的关联关系, 本文分别对高钾玻璃和铅钡玻璃样本组, 计算所有化学成分两两之间的皮尔逊相关系数。

对于高钾玻璃, 各化学成分之间的相关性普遍较弱, 没有一对成分的相关系数绝对值达到 0.7 以上的强相关阈值。这表明高钾玻璃内部的化学成分组成较为独立, 各成分之间的线性关联不显著。

对于铅钡玻璃, 化学成分之间呈现出丰富的强相关关系, 共有 11 对成分的相关系数绝对值达到 0.7 以上。其中, 二氧化硅 (SiO_2) 与氧化铅 (PbO) 之间存在极强的负相关关系

($r = -0.9764$)，二氧化硅 (SiO_2) 与氧化钡 (BaO) 之间也存在强负相关 ($r = -0.950$)。此外，氧化铅 (PbO) 与氧化钡 (BaO) 之间存在强正相关 ($r = 0.983$)，氧化钾 (K_2O) 与氧化钙 (CaO) 之间也存在强正相关 ($r = 0.958$)。

4.5.2 关联网络构建与分析

为进一步刻画两类玻璃在成分关联模式上的结构性差异，本文构建了基于相关系数的无向加权关联网络。网络的节点为各化学成分，边表示两个成分之间的相关系数绝对值达到强相关阈值 ($|r| \geq 0.7$)。

高钾玻璃的关联网络包含 11 个节点，但没有任何边，平均度为 0，平均聚类系数为 0。这表明高钾玻璃内部各成分之间缺乏显著的线性关联，成分组成较为随机。

铅钡玻璃的关联网络包含 11 个节点和 11 条边，平均度为 2.0，平均聚类系数为 0.4303。网络呈现出紧密的关联结构，其中二氧化硅 (SiO_2) 作为网络的核心节点，与氧化钾 (K_2O)、氧化钙 (CaO)、氧化铅 (PbO)、氧化钡 (BaO)、五氧化二磷 (P_2O_5) 等成分均存在强相关关系。图4展示了铅钡玻璃的关联网络。




图 4: 铅钡玻璃化学成分关联网络图

4.5.3 差异性量化

为定量比较两类玻璃在成分关联模式上的差异性，本文采用 Fisher Z 变换对同类成分对的相关系数进行差异显著性检验。变换后的统计量 Z_{diff} 服从标准正态分布，若 $|Z_{diff}| > 1.96$ (对应 $\alpha = 0.05$)，则认为两个相关系数存在显著差异。

检验结果表明，两类玻璃共有 0 对化学成分的相关性存在显著差异。这一结果虽然看似矛盾，但实则反映了高钾玻璃和铅钡玻璃在成分关联模式上的本质差异：铅钡玻璃内部存在大量强相关关系，而高钾玻璃内部几乎不存在强相关关系，这种结构性差异本身就是两类玻璃在成分关联模式上最显著的差异。

4.6 模型求解结果汇总

表 2: 模型求解关键结果汇总

指标	数值
风化与纹饰关联 p 值	4.7×10^{-5}
风化与纹饰 Cramér's V	0.5454
风化前预测模型平均 R^2	1.0
决策树交叉验证准确率	86.92%
高钾玻璃最佳亚类数	6
铅钡玻璃最佳亚类数	7
未知样本铅钡预测数	5
未知样本高钾预测数	3
高钾网络强相关边数	0
铅钡网络强相关边数	11
铅钡网络平均聚类系数	0.4303

5 模型的检验

为评估模型对参数变化的敏感程度，本文对关键模型参数进行了灵敏度分析。通过逐一改变参数取值，观察模型性能指标的变化幅度，从而判断模型的稳健性。

5.1 决策树最大深度灵敏度分析

决策树的最大深度（max_depth）是控制模型复杂度的关键超参数。本文在基准值的基础上，分别将最大深度减小 20%、减小 10%、增大 10% 和增大 20%，观察决策树分类准确率的变化。

实验结果表明，当最大深度在基准值附近变化时，决策树的分类准确率始终保持为 86.92%，变化百分比均为 0.0%。这说明在该数据集上，决策树模型对最大深度这一参数不敏感，模型具有较好的稳健性。图5展示了准确率随最大深度变化的情况。

5.2 聚类数灵敏度分析

亚类划分中，聚类数 k 是决定聚类结果的关键参数。本文在基准值的基础上，分别将聚类数减小 20%、减小 10%、增大 10% 和增大 20%，观察轮廓系数的变化。

实验结果表明，当聚类数变化时，轮廓系数发生了显著变化。具体而言，当聚类数减小 20% 时，轮廓系数从基准值 0.3225 下降至 0.2845，变化百分比为-11.79%；当聚类数减小 10%




图 5: 决策树最大深度灵敏度分析图

时，轮廓系数下降至 0.3210，变化百分比为-0.46%；当聚类数增大 10% 时，轮廓系数保持不变（0.3225，变化百分比为 0.0%）；当聚类数增大 20% 时，轮廓系数上升至 0.3588，变化百分比为 11.26%。

这一结果表明，亚类划分模型对聚类数 k 较为敏感。当 k 值偏离最佳值时，聚类质量会显著下降（ k 减小）或略有提升（ k 增大）。然而，考虑到轮廓系数的绝对变化幅度有限，且最佳 k 值是通过肘部法和轮廓系数共同确定的，本文认为亚类划分结果在合理范围内是稳健的。图6展示了轮廓系数随聚类数变化的情况。




图 6: 聚类数灵敏度分析图

5.3 关联网络阈值灵敏度分析

关联网络构建中，强相关阈值 ρ_{th} 决定了哪些相关系数被视为有效边。本文在基准值 0.7 的基础上，分别将阈值减小 20%、减小 10%、增大 10% 和增大 20%，观察铅钡玻璃关联网络中强相关边数的变化。

实验结果表明,当阈值在 0.56 至 0.84 的范围内变化时,铅钽玻璃关联网络中的强相关边数始终保持为 11 条,变化百分比均为 0.0%。这说明铅钽玻璃内部的强相关关系非常稳健,不会因阈值的微小变化而改变。图7展示了强相关边数随阈值变化的情况。




图 7: 关联网络阈值灵敏度分析图

5.4 综合结论

综合上述灵敏度分析结果,可以得出以下结论:

1. 决策树分类模型对最大深度参数不敏感,模型具有较好的稳健性。
2. 亚类划分模型对聚类数 k 较为敏感,但最佳 k 值的选择有明确的统计依据(肘部法和轮廓系数),因此聚类结果在合理范围内是可靠的。
3. 关联网络构建对强相关阈值不敏感,铅钽玻璃内部的强相关关系具有高度的稳健性。

整体而言,本文所建立的模型对关键参数的变化具有较好的稳健性,模型结论是可靠的。

6 模型的评价与推广

6.1 模型的优点

本文建立的数学模型体系具有以下优点:

1. **逻辑清晰,层次递进:** 模型从描述性统计和预测,到分类与聚类,再到关系挖掘,层层递进,完整地解决了题目提出的四个子问题,形成了从数据到知识的完整链条。
2. **方法成熟,结果可靠:** 采用的卡方检验、线性回归、决策树、K-means 聚类、皮尔逊相关分析等方法均为经典的统计学和机器学习方法,理论基础扎实,结果具有可解释性。
3. **考虑物理化学背景:** 模型充分考虑了风化过程对成分数据的影响,建立了成分预测模型;在聚类分析前进行 CLR 变换,解决了成分数据的定和问题;这些处理使得模型更符合实际物理化学过程。

4. **多维度验证模型稳健性：**通过交叉验证评估分类模型的泛化能力，通过灵敏度分析检验模型对参数变化的敏感程度，通过风化校正分析评估分类结果的可靠性，确保了模型结论的稳健性。

6.2 模型的缺点

尽管模型取得了较好的效果，但仍存在以下不足：

1. **样本量有限：**已知有效样本仅有 67 个，其中高钾玻璃样本仅 18 个，样本量偏小可能影响模型的统计显著性和泛化能力。
2. **风化预测模型假设过于简化：**模型假设风化过程为线性变换，而实际风化过程可能更为复杂，包含非线性效应和元素间的相互作用。
3. **聚类结果的解释性不足：**虽然通过 K-means 聚类得到了亚类划分，但对各亚类的考古学或化学解释尚不够深入，需要更多的领域知识支撑。
4. **未考虑空间位置信息：**同一文物不同采样点的空间位置信息（如部位 1、部位 2）未被充分利用，可能丢失了部分有用信息。

6.3 模型的推广

本文建立的模型体系具有良好的推广价值：

1. **应用于其他文物类型：**模型的分析框架（关联分析 → 分类预测 → 关系挖掘）可推广至其他类型的文物成分数据，如青铜器、陶瓷器等。
2. **引入更先进的机器学习方法：**未来可尝试使用随机森林、梯度提升树等集成学习方法提升分类性能，或使用谱聚类、DBSCAN 等更灵活的聚类方法进行亚类划分。
3. **结合深度学习进行成分预测：**对于风化预测问题，可尝试使用神经网络等非线性模型捕捉更复杂的风化模式，特别是当样本量足够大时。
4. **构建成分数据库与知识图谱：**将分析结果与考古学知识相结合，构建古代玻璃成分数据库和知识图谱，为文物溯源和工艺研究提供更全面的支持。